

LAPORAN AKADEMIS
UJIAN AKHIR SEMESTER MATA KULIAH JARINGAN SYARAF
TIRUAN

SISTEM PEMILIHAN SSD BERDASARKAN KEBUTUHAN LAPTOP DAN
BUDGET MENGGUNAKAN JARINGAN SYARAF TIRUAN (JST)

Disusun oleh:

Felan ardenta yoga adiyatama

NIM 1123150086

PROGRAM STUDI TEKNIK INFORMATIKA

Global Institute | Institut Teknologi dan Bisnis Bina Sarana Global
2026

DAFTAR ISI

BAB I PENDAHULUAN	4
1.1 Latar Belakang.....	4
1.2 Rumusan Masalah	6
1.3 Tujuan Penelitian	6
1.4 Manfaat Penelitian	6
BAB II LANDASAN TEORI	7
2.1 Pengertian Jaringan Syaraf Tiruan	7
2.2 Arsitektur Jaringan Syaraf Tiruan	7
2.3 Konsep Neuron Buatan	S7
2.4 Fungsi Aktivasi.....	8
2.5 Perceptron	8
2.6 Learning Vector Quantization (LVQ).....	8
2.7 Dataset dan Preprocessing Data	9
2.8 Konsep Klasifikasi dan Rekomendasi	9
2.9 SSD SATA.....	10
2.10 SSD NVMe	10
2.11 Faktor Kompatibilitas SSD dengan Laptop	10
BAB III PERANCANGAN MODEL JST	12
3.1 Model 1: Perceptron untuk Klasifikasi Kompatibilitas.....	12
3.1.1 Variabel Input	12
3.1.2 Variabel Output	12
3.1.3 Arsitektur, Bobot, dan Bias.....	12
3.1.4 Fungsi Aktivasi Step Function	12
3.1.5 Learning Rate dan Epoch	13
3.2 Model 2: LVQ untuk Rekomendasi Kategori SSD.....	13
3.2.1 Variabel Input	13
3.2.2 Variabel Output (Kelas)	13
3.2.3 Arsitektur dan Prototype Vector	13
3.2.4 Distance Calculation	14
3.2.5 Update Weight LVQ	14
3.2.6 Learning Rate dan Epoch	14
BAB IV PERHITUNGAN MATEMATIS	15
4.1 Perhitungan Manual Perceptron	15
4.1.1 Iterasi Pertama (Prediksi Benar)	15

4.1.2 Iterasi Kedua (Prediksi Salah dan Update Bobot)	15
4.2 Perhitungan Manual LVQ	16
4.2.1 Penentuan Prototype Winner	16
4.2.2 Update Bobot Prototype	16
BAB V IMPLEMENTASI DAN ANALISIS	18
5.1 Hasil Training Perceptron	18
5.2 Hasil Training LVQ.....	18
5.3 Pengaruh Learning Rate.....	18
5.4 Pengaruh Epoch	18
5.5 Analisis Akurasi	19
5.6 Analisis Grafik Training.....	19
5.7 Kelebihan dan Kekurangan Metode.....	19
5.7.1 Perceptron.....	19
5.7.2 LVQ	20
BAB VI KESIMPULAN DAN SARAN.....	21
6.1 Kesimpulan	21
6.2 Saran Pengembangan.....	21
LAMPIRAN.....	22
A. Daftar Library yang Digunakan.....	22
B. Contoh Struktur Dataset SSD (5 dari 20 Data).....	22
C. Spesifikasi Teknis Aplikasi	22
DAFTAR PUSTAKA	24

BAB I PENDAHULUAN

1.1 Latar Belakang

Kebutuhan terhadap media penyimpanan data yang cepat dan andal terus meningkat seiring dengan berkembangnya komputasi modern, mulai dari penggunaan harian seperti pekerjaan perkantoran hingga kebutuhan berat seperti pengolahan data, rendering video, dan pelatihan model kecerdasan buatan. Lembaga riset pasar Precedence Research mencatat bahwa nilai pasar solid state drive (SSD) secara global mencapai sekitar 55,73 miliar dolar AS pada tahun 2025 dan diproyeksikan tumbuh hingga 266,68 miliar dolar AS pada tahun 2035 dengan tingkat pertumbuhan tahunan gabungan sebesar 18,52 persen (Precedence Research, 2026). Pertumbuhan ini menunjukkan bahwa SSD telah menjadi komponen utama dalam ekosistem komputasi modern, menggantikan peran hard disk drive (HDD) yang selama puluhan tahun menjadi media penyimpanan utama pada laptop dan komputer pribadi.

Secara teknis, SSD memiliki keunggulan jauh di atas HDD karena tidak menggunakan komponen mekanis yang berputar. HDD menyimpan data pada piringan magnetik yang membutuhkan waktu pencarian fisik (seek time) dan kecepatan putar (RPM) untuk membaca data, sementara SSD menyimpan data pada chip NAND flash yang dapat diakses secara elektronik tanpa keterlambatan mekanis. Perbandingan yang dipaparkan oleh Atlantic.net menunjukkan bahwa SSD kelas enterprise berbasis SATA memiliki latensi sekitar 36 mikrodetik, sedangkan SSD berbasis NVMe dapat mencapai latensi serendah 5 mikrodetik (Atlantic.net, 2026). Perbedaan latensi tersebut berdampak langsung pada kecepatan boot sistem operasi, waktu buka aplikasi, dan kelancaran multitasking pada laptop.

Meskipun seluruh SSD lebih unggul dibandingkan HDD, variasi yang ada di dalam keluarga SSD sendiri juga sangat besar. SSD dengan antarmuka SATA dibatasi oleh bus dengan kecepatan maksimum 6 Gbps dan umumnya hanya mampu mencapai sekitar 100.000 IOPS (input output per second), sedangkan SSD dengan antarmuka NVMe yang berjalan di atas jalur PCI Express dapat melampaui 1.000.000 IOPS pada kondisi tertentu (TechTarget, 2024). Studi benchmark yang dilakukan ServerMania bahkan menemukan bahwa pada queue depth 32, yang merupakan kondisi umum pada beban kerja basis data, NVMe dapat mencapai sekitar 650.000

IOPS dibandingkan SATA yang mentok di kisaran 95.000 IOPS, dengan throughput transaksi basis data MySQL yang lebih tinggi 3,8 kali lipat (ServerMania, 2026). Perbedaan sebesar ini membuat pemilihan jenis SSD bukan lagi sekadar soal kapasitas, melainkan juga soal kesesuaian antarmuka dengan kebutuhan pemakaian dan dengan slot yang tersedia pada motherboard laptop.

Pada praktiknya, banyak pengguna laptop memilih SSD hanya berdasarkan dua pertimbangan sederhana, yaitu kapasitas penyimpanan dan harga termurah yang tersedia di pasaran. Pendekatan ini sering mengabaikan faktor penting lain seperti jenis slot yang didukung laptop (M.2 NVMe, M.2 SATA, atau 2.5 inci SATA), generasi PCI Express yang didukung motherboard, serta intensitas penggunaan harian pengguna. Akibatnya muncul dua jenis masalah yang berlawanan. Masalah pertama adalah pemborosan biaya, yaitu ketika pengguna dengan kebutuhan ringan seperti pekerjaan administrasi membeli SSD NVMe kelas tinggi yang harganya jauh lebih mahal tanpa benar benar memanfaatkan kecepatannya. Masalah kedua adalah performa yang tidak memadai, yaitu ketika pengguna dengan kebutuhan berat seperti rendering video atau pengembangan perangkat lunak memilih SSD SATA murah yang justru menjadi penghambat kinerja keseluruhan sistem.

Untuk mengatasi masalah pengambilan keputusan yang kompleks seperti ini, pendekatan berbasis Jaringan Syaraf Tiruan (JST) menawarkan keunggulan dibandingkan pendekatan pemrograman prosedural konvensional yang hanya mengandalkan struktur kondisional if else. Sistem berbasis aturan statis cenderung sulit dipelihara ketika jumlah kombinasi kondisi bertambah banyak, sebab setiap kombinasi baru harus didefinisikan secara manual oleh programmer (Russell & Norvig, 2021). Sebaliknya, JST belajar dari data historis untuk membentuk pola keputusan secara otomatis, sehingga lebih mampu menggeneralisasi terhadap kombinasi kebutuhan pengguna yang belum pernah ditemui sebelumnya. Konsep pembelajaran adaptif ini pertama kali diperkenalkan secara formal oleh Rosenblatt (1958) melalui model Perceptron, dan kemudian diperluas oleh Kohonen melalui pendekatan pembelajaran kompetitif yang dikenal sebagai Learning Vector Quantization atau LVQ (Kohonen, 1990). Kedua model inilah yang menjadi dasar perancangan sistem pada proyek ini, dengan Perceptron digunakan untuk menentukan kompatibilitas SSD terhadap laptop, dan LVQ digunakan untuk

merekomendasikan kategori SSD yang paling sesuai dengan kebutuhan dan budget pengguna.

1.2 Rumusan Masalah

1. Bagaimana merancang model Perceptron yang dapat mengklasifikasikan kompatibilitas antara SSD dan laptop berdasarkan jenis slot, generasi motherboard, dan dukungan NVMe?
2. Bagaimana merancang model Learning Vector Quantization (LVQ) yang dapat memberikan rekomendasi kategori SSD yang sesuai berdasarkan budget, kebutuhan penggunaan, kapasitas penyimpanan, dan intensitas pemakaian pengguna?
3. Bagaimana pengaruh learning rate dan jumlah epoch terhadap proses pelatihan dan tingkat akurasi kedua model tersebut?
4. Bagaimana mengintegrasikan kedua model ke dalam satu aplikasi interaktif yang dapat digunakan secara langsung oleh pengguna akhir?

1.3 Tujuan Penelitian

1. Membangun model Perceptron dari prinsip dasar (from scratch) untuk klasifikasi kompatibilitas SSD terhadap laptop.
2. Membangun model LVQ dari prinsip dasar (from scratch) untuk rekomendasi kategori SSD.
3. Mengimplementasikan kedua model ke dalam aplikasi berbasis Streamlit dengan antarmuka yang interaktif dan mudah digunakan.
4. Menganalisis pengaruh parameter learning rate dan epoch terhadap konvergensi dan akurasi masing masing model.

1.4 Manfaat Penelitian

Manfaat dari penelitian ini dapat dijabarkan dari tiga sudut pandang yang berbeda sebagai berikut.

- Bagi pengguna umum, sistem ini membantu menentukan SSD yang sesuai dengan kebutuhan dan budget tanpa perlu memahami detail teknis spesifikasi hardware secara mendalam.
- Bagi kalangan akademis, penelitian ini memberikan contoh penerapan Perceptron dan LVQ pada studi kasus yang lebih dekat dengan permasalahan nyata di bidang teknologi informasi, melengkapi studi kasus klasik seperti logic gate atau data akademik.
- Bagi pengembang sistem, hasil penelitian ini dapat dijadikan rujukan dalam mengembangkan sistem rekomendasi berbasis JST untuk produk hardware lain seperti RAM, prosesor, atau kartu grafis.

BAB II LANDASAN TEORI

2.1 Pengertian Jaringan Syaraf Tiruan

Jaringan Syaraf Tiruan merupakan model komputasi yang meniru cara kerja jaringan neuron biologis pada otak manusia, dirancang untuk mengenali pola dan mengambil keputusan berdasarkan data yang pernah dipelajari sebelumnya (Fausset, 1994). Konsep ini pertama kali diformalkan secara matematis oleh Rosenblatt melalui model Perceptron sebagai model probabilistik untuk penyimpanan dan pengorganisasian informasi pada otak (Rosenblatt, 1958). Siang (2009) menjelaskan bahwa JST belajar melalui proses penyesuaian bobot koneksi antar neuron secara berulang berdasarkan data masukan dan keluaran yang diharapkan, sehingga sistem mampu menggeneralisasi pola dari data latih ke data baru yang belum pernah dilihat sebelumnya.

2.2 Arsitektur Jaringan Syaraf Tiruan

Secara umum arsitektur JST terdiri dari lapisan input yang menerima data mentah, lapisan tersembunyi (opsional pada arsitektur tertentu) yang melakukan transformasi non linear, dan lapisan output yang menghasilkan keputusan akhir (Fausset, 1994). Pada penelitian ini digunakan dua arsitektur yang berbeda, yaitu Perceptron satu lapis yang hanya memiliki lapisan input dan output, serta LVQ yang menggunakan struktur kompetitif dengan vektor prototipe sebagai representasi setiap kelas keluaran. Kedua arsitektur ini dipilih karena kesederhanaannya membuat proses pembelajaran dapat diimplementasikan langsung menggunakan operasi matriks NumPy tanpa bergantung pada pustaka deep learning yang lebih kompleks.

2.3 Konsep Neuron Buatan

Neuron buatan merupakan unit komputasi dasar dalam JST yang menerima beberapa nilai input x_1 hingga x_n , mengalikan setiap input dengan bobot w_i yang merepresentasikan kekuatan koneksi, menambahkan bias b sebagai nilai ambang, lalu menjumlahkan seluruhnya menjadi nilai net. Nilai net tersebut kemudian diteruskan ke fungsi aktivasi untuk menghasilkan output neuron (Rosenblatt, 1958). Proses pembelajaran pada neuron buatan dilakukan dengan menyesuaikan nilai bobot dan bias secara iteratif sampai output yang dihasilkan mendekati target yang diinginkan.

2.4 Fungsi Aktivasi

Fungsi aktivasi menentukan bagaimana nilai net pada sebuah neuron diubah menjadi output akhir. Pada model Perceptron klasik, fungsi aktivasi yang digunakan adalah fungsi step (Heaviside) yang menghasilkan output biner, yaitu nilai 1 apabila net lebih besar atau sama dengan nol, dan nilai 0 apabila net kurang dari nol (Rosenblatt, 1958). Fungsi ini dipilih karena kesesuaiannya dengan masalah klasifikasi dua kelas pada kasus kompatibilitas SSD, yaitu kompatibel atau tidak kompatibel. Fungsi aktivasi lain seperti sigmoid atau ReLU umumnya digunakan pada arsitektur JST yang lebih kompleks dengan banyak lapisan tersembunyi, namun tidak digunakan pada penelitian ini karena permasalahan yang diselesaikan bersifat klasifikasi linear sederhana.

2.5 Perceptron

Perceptron adalah model JST satu lapis yang dikembangkan oleh Rosenblatt sebagai classifier linear yang mampu memisahkan dua kelas data berdasarkan garis pemisah linear (Rosenblatt, 1958). Algoritma pembelajaran Perceptron bekerja dengan cara membandingkan output yang dihasilkan dengan target yang diinginkan, kemudian memperbarui bobot apabila terjadi kesalahan prediksi. Proses ini akan terus diulang selama beberapa epoch sampai seluruh data latih terklasifikasi dengan benar, dengan catatan data tersebut harus bersifat linearly separable. Penerapan Perceptron pada studi kasus nyata di lingkungan akademik Indonesia telah dilakukan pada berbagai konteks, misalnya dalam penentuan pola sistem irigasi lahan pertanian (Yanto, Sovia, & Mandala, 2018), pembagian jurusan siswa yang mencapai akurasi hingga 98 persen (Grania, 2017), serta penilaian pengetahuan siswa (Kapita, 2020). Berbagai penerapan tersebut menunjukkan bahwa Perceptron cukup andal digunakan pada permasalahan klasifikasi dua kelas dengan jumlah fitur input yang relatif sedikit, sehingga relevan untuk diterapkan pada masalah klasifikasi kompatibilitas SSD yang juga melibatkan fitur input terbatas.

2.6 Learning Vector Quantization (LVQ)

LVQ adalah metode klasifikasi berbasis pembelajaran kompetitif yang dikembangkan oleh Kohonen sebagai pengembangan dari konsep Self-Organizing Map, namun bekerja secara supervised dengan memanfaatkan label kelas pada data latih (Kohonen, 1986; Kohonen, 1990). Setiap kelas keluaran direpresentasikan oleh

satu atau lebih vektor prototipe (codebook vector) yang ditempatkan pada ruang fitur. Pada saat pelatihan, vektor prototipe yang paling dekat dengan data input (disebut sebagai pemenang atau winner) akan diperbarui posisinya mendekati data input apabila kelas keduanya sama, dan akan digeser menjauh apabila kelasnya berbeda. LVQ telah banyak diterapkan pada penelitian klasifikasi di Indonesia, antara lain untuk klasifikasi status gizi anak yang menemukan bahwa varian LVQ3 memberikan akurasi lebih baik dibandingkan LVQ1 (Budianita, Santoso, & Rahayudi, 2013), prediksi penjurusan siswa SMA (Meliawati, 2016), klasifikasi abstrak tesis (Hariri, Utami, & Amborowati, 2015), serta analisis sentimen pengguna aplikasi transportasi daring (Pratama, Budianita, Yanti, & Candra, 2018). Karakteristik LVQ yang mampu menangani klasifikasi multi kelas dengan baik menjadikannya pilihan yang tepat untuk merekomendasikan empat kategori SSD pada penelitian ini, yaitu Entry Level, Mid Range, High Performance, dan Professional.

2.7 Dataset dan Preprocessing Data

Sebelum data digunakan untuk melatih JST, diperlukan tahap preprocessing agar data berada pada skala yang seragam dan tidak mendominasi proses pembelajaran karena perbedaan rentang nilai antar fitur (Fausset, 1994). Pada penelitian ini, fitur numerik seperti budget dan kapasitas penyimpanan dinormalisasi menggunakan teknik min max scaling ke rentang 0 sampai 1, sedangkan fitur kategorikal seperti kebutuhan penggunaan dan intensitas pemakaian diubah menjadi nilai ordinal numerik. Tahap ini penting khususnya untuk model LVQ yang sangat bergantung pada perhitungan jarak Euclidean, sebab fitur dengan rentang nilai yang jauh lebih besar dapat mendominasi hasil perhitungan jarak apabila tidak dinormalisasi terlebih dahulu.

2.8 Konsep Klasifikasi dan Rekomendasi

Klasifikasi merupakan proses menentukan kelas atau kategori dari suatu data berdasarkan fitur-fitur yang dimilikinya, sedangkan sistem rekomendasi merupakan sistem yang menyarankan pilihan terbaik kepada pengguna berdasarkan preferensi atau kondisi tertentu (Russell & Norvig, 2021). Pada penelitian ini, kedua konsep tersebut digabungkan secara berurutan, yaitu Perceptron melakukan klasifikasi biner untuk memastikan kompatibilitas teknis SSD terhadap laptop, kemudian LVQ melakukan klasifikasi multi kelas untuk menentukan kategori SSD yang paling

direkomendasikan, dan hasil akhir berupa SSD spesifik diambil dari dataset berdasarkan kategori yang telah ditentukan tersebut.

2.9 SSD SATA

SSD dengan antarmuka SATA (Serial Advanced Technology Attachment) menggunakan protokol AHCI yang awalnya dirancang untuk HDD dan hanya mendukung satu antrian perintah (command queue) dengan kedalaman antrian yang terbatas. Akibat keterbatasan ini, SSD SATA umumnya memiliki throughput maksimum sekitar 6 Gbps dengan IOPS yang berada pada kisaran 100.000 dan latensi di atas 100 mikrodetik (TechTarget, 2024). Meskipun demikian, SSD SATA tetap relevan untuk kebutuhan komputasi ringan hingga menengah seperti penggunaan perkantoran, pencarian web, dan multimedia ringan, karena harganya yang jauh lebih terjangkau dibandingkan SSD NVMe pada kapasitas yang setara (Coherent Market Insights, 2026).

2.10 SSD NVMe

SSD dengan antarmuka NVMe (Non-Volatile Memory Express) berkomunikasi langsung melalui jalur PCI Express tanpa melalui kontroler AHCI, sehingga mampu memanfaatkan banyak antrian perintah secara paralel. Hal ini membuat NVMe memiliki throughput dan IOPS yang jauh lebih tinggi dibandingkan SATA, dengan sebagian implementasi mampu melampaui 1.000.000 IOPS pada kondisi pengujian tertentu (1gbits, 2026). Standar NVMe sendiri terus diperbarui oleh konsorsium NVM Express, dengan versi NVMe 2.1 dirilis pada Agustus 2024 untuk menambahkan dukungan fitur baru pada manajemen daya dan keamanan data (TechTarget, 2024). SSD NVMe sangat sesuai untuk kebutuhan komputasi berat seperti pengembangan perangkat lunak, pengeditan video, gaming, dan pelatihan model kecerdasan buatan pada skala kecil.

2.11 Faktor Kompatibilitas SSD dengan Laptop

Kompatibilitas antara SSD dan laptop ditentukan oleh beberapa faktor teknis yang harus dipertimbangkan secara bersamaan. Faktor pertama adalah bentuk fisik dan jenis slot, di mana SSD M.2 dapat menggunakan keying B-key untuk SATA atau M-key untuk NVMe, sementara SSD 2.5 inci memerlukan konektor SATA konvensional. Faktor kedua adalah generasi PCI Express yang didukung motherboard laptop, sebab

SSD NVMe generasi baru seperti PCIe Gen4 atau Gen5 tetap dapat berjalan pada slot Gen3, namun kecepatannya akan dibatasi mengikuti kemampuan slot yang lebih rendah. Faktor ketiga adalah dukungan firmware dan BIOS laptop terhadap protokol NVMe, karena sebagian laptop generasi lama hanya mendukung protokol AHCI pada slot M.2 yang dimilikinya. Ketiga faktor inilah yang menjadi dasar perancangan fitur input pada model Perceptron dalam penelitian ini, yaitu jenis slot laptop, generasi laptop, dan status dukungan NVMe.

BAB III PERANCANGAN MODEL JST

3.1 Model 1: Perceptron untuk Klasifikasi Kompatibilitas

Model pertama dirancang untuk menjawab pertanyaan biner, yaitu apakah sebuah SSD kompatibel dengan laptop pengguna atau tidak. Model ini menggunakan arsitektur Perceptron satu lapis dengan tiga neuron input dan satu neuron output, tanpa lapisan tersembunyi, sesuai dengan arsitektur Perceptron klasik yang diperkenalkan oleh Rosenblatt (1958).

3.1.1 Variabel Input

- x_1 - Jenis Slot Laptop, dikodekan 1 apabila laptop memiliki slot M.2 NVMe dan 0 apabila hanya memiliki slot M.2 SATA atau SATA 2.5 inci.
- x_2 - Generasi Laptop, dikodekan 1 apabila motherboard mendukung PCIe generasi 3 ke atas dan 0 apabila tidak mendukung NVMe sama sekali.
- x_3 - Dukungan NVMe pada SSD, dikodekan 1 apabila SSD yang dipilih berjenis NVMe dan 0 apabila berjenis SATA.

3.1.2 Variabel Output

Output model berupa nilai biner, yaitu 1 yang merepresentasikan SSD Kompatibel dan 0 yang merepresentasikan SSD Tidak Kompatibel. Logika dasarnya adalah SSD SATA akan selalu kompatibel dengan slot apapun, sementara SSD NVMe hanya kompatibel apabila laptop memiliki slot M.2 NVMe dan motherboard mendukung protokol NVMe.

3.1.3 Arsitektur, Bobot, dan Bias

Arsitektur jaringan terdiri dari tiga input yang masing masing terhubung ke satu neuron output melalui bobot w_1 , w_2 , dan w_3 , ditambah satu bias b . Bobot diinisialisasi dengan nilai kecil mendekati nol atau menggunakan inisialisasi acak terbatas (misalnya pada rentang -0,5 sampai 0,5) sebelum proses pelatihan dimulai. Bias berfungsi sebagai ambang batas yang menggeser garis keputusan agar tidak selalu melewati titik nol pada ruang fitur.

3.1.4 Fungsi Aktivasi Step Function

$$f(net) = 1, \text{ jika } net \geq 0 \quad / \quad f(net) = 0, \text{ jika } net < 0$$

Fungsi step dipilih karena keluaran yang dibutuhkan bersifat biner dan tegas, sejalan dengan kebutuhan keputusan kompatibel atau tidak kompatibel yang tidak memerlukan nilai probabilitas kontinu.

3.1.5 Learning Rate dan Epoch

Learning rate (α) yang digunakan pada model ini adalah 0,1. Nilai ini dipilih relatif kecil agar proses pembaruan bobot berlangsung secara bertahap dan stabil, mengingat permasalahan kompatibilitas SSD bersifat linearly separable sehingga konvergensi dapat dicapai tanpa memerlukan learning rate yang besar. Jumlah epoch maksimum ditetapkan sebanyak 100 epoch, dengan mekanisme penghentian dini (early stopping) apabila seluruh data latih telah terklasifikasi dengan benar sebelum mencapai epoch maksimum.

3.2 Model 2: LVQ untuk Rekomendasi Kategori SSD

Model kedua dirancang untuk menjawab pertanyaan multi kelas, yaitu kategori SSD apa yang paling sesuai dengan kebutuhan dan budget pengguna. Model ini menggunakan arsitektur LVQ dengan empat vektor prototipe yang masing masing merepresentasikan satu kategori SSD, sesuai dengan prinsip pembelajaran kompetitif yang dikembangkan oleh Kohonen (1990).

3.2.1 Variabel Input

- x1 - Budget pengguna dalam Rupiah, dinormalisasi ke rentang 0 sampai 1 menggunakan min max scaling berdasarkan budget minimum dan maksimum pada dataset.
- x2 - Kebutuhan penggunaan, dikodekan secara ordinal yaitu 1 untuk Perkantoran/Office, 2 untuk Multimedia, 3 untuk Gaming, dan 4 untuk Content Creation/Profesional.
- x3 - Kapasitas penyimpanan yang diinginkan dalam GB, dinormalisasi ke rentang 0 sampai 1.
- x4 - Intensitas penggunaan, dikodekan secara ordinal yaitu 1 untuk Ringan, 2 untuk Sedang, dan 3 untuk Berat.

3.2.2 Variabel Output (Kelas)

- Kelas 1 - SSD Entry Level, untuk kebutuhan ringan dengan budget terbatas.
- Kelas 2 - SSD Mid Range, untuk kebutuhan harian dengan budget menengah.
- Kelas 3 - SSD High Performance, untuk kebutuhan gaming dan produktivitas tinggi.
- Kelas 4 - SSD Professional, untuk kebutuhan profesional seperti rendering dan komputasi data berat.

3.2.3 Arsitektur dan Prototype Vector

Setiap kelas keluaran direpresentasikan oleh satu vektor prototipe berdimensi empat yang nilainya diinisialisasi dari rata rata data latih pada masing masing kelas.

Penggunaan satu prototipe per kelas dipilih agar proses pelatihan dan interpretasi hasil tetap sederhana, sesuai dengan varian dasar LVQ1 yang diperkenalkan Kohonen (1986) sebelum dikembangkan lebih lanjut menjadi LVQ2 dan LVQ3.

3.2.4 Distance Calculation

$$d(x, w) = \sqrt{\sum (x_i - w_i)^2}$$

Jarak antara data input dan setiap vektor prototipe dihitung menggunakan Euclidean distance. Prototipe dengan jarak terkecil terhadap data input akan ditetapkan sebagai pemenang (winner) yang menentukan kelas prediksi untuk data tersebut.

3.2.5 Update Weight LVQ

$$w_{baru} = w_{lama} + \alpha (x - w_{lama}), \text{ jika prediksi benar}$$

$$w_{baru} = w_{lama} - \alpha (x - w_{lama}), \text{ jika prediksi salah}$$

Apabila kelas pemenang sesuai dengan label data latih, prototipe akan digerakkan mendekati data input untuk memperkuat representasi kelas tersebut. Sebaliknya, apabila kelas pemenang tidak sesuai dengan label data latih, prototipe akan digerakkan menjauhi data input agar batas antar kelas menjadi lebih jelas pada iterasi berikutnya.

3.2.6 Learning Rate dan Epoch

Learning rate awal yang digunakan pada model LVQ adalah 0,2, dengan skema peluruhan (decay) di mana learning rate dikurangi secara bertahap pada setiap epoch menggunakan rumus $\alpha(t+1) = 0,5 \times \alpha(t)$ setiap kelipatan tertentu epoch, sesuai dengan praktik umum pelatihan LVQ yang disarankan oleh Kohonen (1990) agar pergerakan prototipe semakin halus mendekati akhir pelatihan. Jumlah epoch yang digunakan adalah 50 epoch, mengingat ukuran dataset yang relatif kecil sehingga konvergensi dapat dicapai lebih cepat dibandingkan model Perceptron.

BAB IV PERHITUNGAN MATEMATIS

4.1 Perhitungan Manual Perceptron

Rumus dasar yang digunakan pada model Perceptron adalah sebagai berikut.

$$\begin{aligned} net &= \sum (w_i \times x_i) + b \\ f(net) &= 1 \text{ jika } net \geq 0, \text{ dan } 0 \text{ jika } net < 0 \\ \Delta w &= \alpha (target - output) \times x_i \quad \Delta b = \alpha (target - output) \end{aligned}$$

4.1.1 Iterasi Pertama (Prediksi Benar)

Misalkan terdapat data uji dengan kondisi laptop memiliki slot M.2 NVMe ($x_1 = 1$), motherboard mendukung PCIe Gen4 sehingga NVMe didukung ($x_2 = 1$), dan SSD yang dipilih berjenis NVMe ($x_3 = 1$), dengan target = 1 (Kompatibel). Bobot awal ditetapkan $w_1 = 0,2$, $w_2 = 0,3$, $w_3 = 0,1$, dan bias $b = -0,1$, dengan learning rate $\alpha = 0,1$.

$$net = (0,2 \times 1) + (0,3 \times 1) + (0,1 \times 1) + (-0,1) = 0,5$$

Karena $net = 0,5 \geq 0$, maka $f(net) = 1$. Output yang dihasilkan (1) sama dengan target (1), sehingga tidak terjadi kesalahan dan bobot tidak perlu diperbarui ($\Delta w_1 = \Delta w_2 = \Delta w_3 = 0$, $\Delta b = 0$).

4.1.2 Iterasi Kedua (Prediksi Salah dan Update Bobot)

Pada data uji berikutnya, laptop hanya memiliki slot SATA ($x_1 = 0$), namun motherboard sebenarnya mendukung NVMe pada slot lain ($x_2 = 1$), sedangkan SSD yang dipilih berjenis NVMe ($x_3 = 1$), dengan target = 0 (Tidak Kompatibel) karena SSD NVMe tidak dapat dipasang pada slot SATA yang tersedia. Bobot yang digunakan adalah bobot hasil iterasi sebelumnya, yaitu $w_1 = 0,2$, $w_2 = 0,3$, $w_3 = 0,1$, dan $b = -0,1$.

$$net = (0,2 \times 0) + (0,3 \times 1) + (0,1 \times 1) + (-0,1) = 0,3$$

Karena $net = 0,3 \geq 0$, maka $f(net) = 1$, padahal target sebenarnya adalah 0. Terjadi kesalahan prediksi, sehingga bobot harus diperbarui menggunakan rumus $\Delta w = \alpha (target - output) \times x_i$.

$$\begin{aligned} \Delta w_1 &= 0,1 \times (0 - 1) \times 0 = 0 & \rightarrow w_1 \text{ baru} &= 0,2 + 0 = 0,2 \\ \Delta w_2 &= 0,1 \times (0 - 1) \times 1 = -0,1 & \rightarrow w_2 \text{ baru} &= 0,3 - 0,1 = 0,2 \\ \Delta w_3 &= 0,1 \times (0 - 1) \times 1 = -0,1 & \rightarrow w_3 \text{ baru} &= 0,1 - 0,1 = 0,0 \\ \Delta b &= 0,1 \times (0 - 1) = -0,1 & \rightarrow b \text{ baru} &= -0,1 - 0,1 = -0,2 \end{aligned}$$

Dengan bobot baru tersebut, apabila data uji kedua dimasukkan kembali, net akan bernilai $(0,2 \times 0) + (0,2 \times 1) + (0,0 \times 1) + (-0,2) = 0,0$, yang menghasilkan $f(\text{net}) = 1$ karena syarat $\text{net} \geq 0$ masih terpenuhi pada batas tepat nol. Hal ini menunjukkan bahwa proses pembaruan bobot bersifat bertahap, dan beberapa iterasi tambahan masih diperlukan sebelum model benar benar konvergen pada seluruh data latih.

4.2 Perhitungan Manual LVQ

Rumus dasar yang digunakan pada model LVQ adalah sebagai berikut.

$$d(x, w) = \sqrt{(\sum (x_i - w_i)^2)}$$

$$w_{\text{baru}} = w_{\text{lama}} + \alpha (x - w_{\text{lama}}) \text{ jika kelas benar}$$

$$w_{\text{baru}} = w_{\text{lama}} - \alpha (x - w_{\text{lama}}) \text{ jika kelas salah}$$

4.2.1 Penentuan Prototype Winner

Misalkan terdapat data pengguna dengan budget menengah (dinormalisasi $x_1 = 0,30$), kebutuhan Multimedia ($x_2 = 2$), kapasitas yang diinginkan 500 GB (dinormalisasi $x_3 = 0,25$ dari skala maksimum 2 TB), dan intensitas Sedang ($x_4 = 2$), dengan label kelas sebenarnya adalah SSD Mid Range. Empat vektor prototipe awal yang digunakan adalah sebagai berikut.

$$W_{\text{Entry}} = [0,10; 1; 0,10; 1] \quad W_{\text{Mid}} = [0,35; 2; 0,30; 2]$$

$$W_{\text{High}} = [0,60; 3; 0,50; 2] \quad W_{\text{Pro}} = [0,90; 4; 0,80; 3]$$

Jarak data input $x = [0,30; 2; 0,25; 2]$ terhadap masing masing prototipe dihitung sebagai berikut.

$$d(x, W_{\text{Entry}}) = \sqrt{(0,20^2 + 1^2 + 0,15^2 + 1^2)} = \sqrt{(0,04 + 1 + 0,0225 + 1)} = \sqrt{2,0625} \approx 1,436$$

$$d(x, W_{\text{Mid}}) = \sqrt{(0,05^2 + 0^2 + 0,05^2 + 0^2)} = \sqrt{(0,0025 + 0 + 0,0025 + 0)} = \sqrt{0,005} \approx 0,071$$

$$d(x, W_{\text{High}}) = \sqrt{(0,30^2 + 1^2 + 0,25^2 + 0^2)} = \sqrt{(0,09 + 1 + 0,0625 + 0)} = \sqrt{1,1525} \approx 1,074$$

$$d(x, W_{\text{Pro}}) = \sqrt{(0,60^2 + 2^2 + 0,55^2 + 1^2)} = \sqrt{(0,36 + 4 + 0,3025 + 1)} = \sqrt{5,6625} \approx 2,380$$

Dari keempat perhitungan tersebut, jarak terkecil dimiliki oleh W_{Mid} dengan nilai sekitar 0,071, sehingga W_{Mid} ditetapkan sebagai prototipe pemenang. Karena kelas pemenang ini sesuai dengan label sebenarnya yaitu SSD Mid Range, maka prototipe W_{Mid} akan diperbarui mendekati data input.

4.2.2 Update Bobot Prototype

Dengan menggunakan learning rate $\alpha = 0,2$, prototipe W_Mid diperbarui sebagai berikut.

$$W_Mid \text{ baru} = [0,35 + 0,2(0,30 - 0,35); 2 + 0,2(2 - 2); 0,30 + 0,2(0,25 - 0,30); 2 + 0,2(2 - 2)]$$

$$W_Mid \text{ baru} = [0,35 - 0,01; 2; 0,30 - 0,01; 2] = [0,34; 2; 0,29; 2]$$

Hasil pembaruan menunjukkan bahwa prototipe SSD Mid Range bergeser sedikit mendekati posisi data input, sehingga pada iterasi berikutnya prototipe tersebut akan semakin representatif terhadap data pengguna dengan kebutuhan Multimedia dan budget menengah. Proses ini diulang untuk seluruh data latih selama 50 epoch dengan learning rate yang meluruh secara bertahap, sehingga keempat prototipe akan konvergen pada posisi yang merepresentasikan masing masing kategori SSD secara optimal.

BAB V IMPLEMENTASI DAN ANALISIS

5.1 Hasil Training Perceptron

Permasalahan kompatibilitas SSD pada dasarnya bersifat hampir linear, karena aturan utamanya cukup sederhana, yaitu SSD SATA hampir selalu kompatibel dengan slot apapun, sementara SSD NVMe hanya kompatibel apabila slot dan motherboard laptop mendukung protokol tersebut. Karena sifat data yang linearly separable inilah, hasil training pada implementasi menunjukkan bahwa model Perceptron mampu konvergen dalam jumlah epoch yang relatif sedikit, biasanya di bawah 20 epoch dari maksimum 100 epoch yang ditetapkan, dengan grafik error yang menurun secara konsisten tanpa fluktuasi berarti.

5.2 Hasil Training LVQ

Model LVQ membutuhkan epoch yang relatif lebih banyak dibandingkan Perceptron untuk mencapai posisi prototipe yang stabil, karena harus menyeimbangkan posisi empat prototipe sekaligus pada ruang fitur berdimensi empat. Pola ini konsisten dengan temuan Budianita, Santoso, dan Rahayudi (2013) yang menunjukkan bahwa performa LVQ sangat dipengaruhi oleh skema pembaruan window dan learning rate yang digunakan, di mana varian LVQ3 dengan parameter window terbukti memberikan hasil klasifikasi yang lebih baik dibandingkan LVQ1 standar pada studi kasus status gizi anak.

5.3 Pengaruh Learning Rate

Learning rate yang terlalu besar pada kedua model menyebabkan pembaruan bobot menjadi terlalu agresif, sehingga proses pelatihan cenderung berosilasi dan sulit mencapai titik konvergen yang stabil. Sebaliknya, learning rate yang terlalu kecil membuat proses pelatihan berjalan sangat lambat dan membutuhkan jumlah epoch yang jauh lebih banyak untuk mencapai hasil yang setara. Pemilihan learning rate 0,1 untuk Perceptron dan 0,2 dengan skema peluruhan untuk LVQ pada penelitian ini merupakan hasil pertimbangan antara kecepatan konvergensi dan kestabilan proses pelatihan.

5.4 Pengaruh Epoch

Jumlah epoch yang terlalu sedikit menyebabkan model belum sempat mempelajari pola data secara menyeluruh sehingga akurasi yang dihasilkan masih

rendah (underfitting). Sebaliknya, jumlah epoch yang berlebihan pada dataset kecil seperti pada penelitian ini berisiko menyebabkan prototipe LVQ terlalu menyesuaikan diri terhadap data latih sehingga generalisasi terhadap data baru dapat menurun. Oleh karena itu, pemantauan akurasi pada setiap epoch melalui grafik training pada aplikasi menjadi penting untuk menentukan titik epoch yang optimal.

5.5 Analisis Akurasi

Berdasarkan precedent penelitian sejenis pada konteks akademik di Indonesia, akurasi yang dicapai pada studi klasifikasi berbasis Perceptron dengan jumlah fitur input terbatas dapat mencapai kisaran 98 persen pada kasus pembagian jurusan siswa (Grania, 2017). Mengacu pada precedent tersebut, model Perceptron pada penelitian ini diharapkan dapat mencapai akurasi yang tinggi pula, mengingat jumlah fitur input dan kompleksitas aturan kompatibilitas SSD relatif lebih sederhana dibandingkan studi kasus pembagian jurusan. Untuk model LVQ, akurasi yang dicapai akan sangat bergantung pada seberapa jelas batas antar kategori SSD pada dataset yang digunakan, khususnya pada data yang berada di wilayah perbatasan antara dua kategori budget yang berdekatan.

5.6 Analisis Grafik Training

Grafik training pada aplikasi menampilkan penurunan nilai error terhadap epoch untuk model Perceptron, serta penurunan rata rata jarak prototipe terhadap data latih untuk model LVQ. Pola grafik yang menurun secara monoton dan mendatar (plateau) pada epoch akhir menjadi indikator bahwa model telah mencapai konvergensi, sementara pola grafik yang masih berfluktuasi pada epoch akhir mengindikasikan perlunya penyesuaian learning rate atau penambahan jumlah epoch.

5.7 Kelebihan dan Kekurangan Metode

5.7.1 Perceptron

Kelebihan utama Perceptron adalah kesederhanaan struktur dan kecepatan komputasi yang sangat tinggi, sehingga sangat sesuai untuk permasalahan klasifikasi dua kelas dengan fitur input yang sedikit seperti kasus kompatibilitas SSD. Namun, kekurangan mendasar Perceptron adalah ketidakmampuannya menyelesaikan permasalahan yang tidak linearly separable, sebagaimana telah dibuktikan secara matematis oleh Minsky dan Papert (1969) melalui kritik terhadap keterbatasan Perceptron pada permasalahan logika XOR. Keterbatasan ini perlu diperhatikan

apabila di masa depan aturan kompatibilitas SSD menjadi lebih kompleks dan tidak lagi bersifat linear.

5.7.2 LVQ

Kelebihan LVQ adalah kemampuannya menangani klasifikasi multi kelas secara intuitif melalui representasi prototipe yang mudah dipahami secara visual, serta fleksibilitasnya untuk ditambah jumlah prototipe per kelas apabila diperlukan. Kekurangannya, performa LVQ cukup sensitif terhadap inisialisasi posisi awal prototipe dan pemilihan skema learning rate, sebagaimana ditemukan pada penelitian klasifikasi status gizi anak yang menunjukkan perbedaan akurasi signifikan antar varian LVQ (Budianita, Santoso, & Rahayudi, 2013).

BAB VI KESIMPULAN DAN SARAN

6.1 Kesimpulan

Penelitian ini berhasil merancang dan mengimplementasikan dua model Jaringan Syaraf Tiruan untuk membantu pengguna memilih SSD yang sesuai dengan kebutuhan laptop dan budget yang dimiliki. Model Perceptron yang dibangun dari prinsip dasar berhasil mengklasifikasikan kompatibilitas SSD terhadap laptop berdasarkan jenis slot, generasi motherboard, dan dukungan NVMe, dengan proses konvergensi yang relatif cepat karena sifat permasalahan yang linearly separable. Model LVQ yang dibangun dari prinsip dasar berhasil mengelompokkan kebutuhan pengguna ke dalam empat kategori SSD, yaitu Entry Level, Mid Range, High Performance, dan Professional, berdasarkan budget, kebutuhan penggunaan, kapasitas, dan intensitas pemakaian.

Kedua model tersebut berhasil diintegrasikan ke dalam satu aplikasi berbasis Streamlit yang interaktif, lengkap dengan dashboard statistik, riwayat rekomendasi, fitur ekspor data ke Excel, serta visualisasi training menggunakan Plotly. Secara keseluruhan, sistem ini menunjukkan bahwa pendekatan JST mampu mengambil keputusan kompatibilitas dan rekomendasi yang lebih adaptif dibandingkan pendekatan pemrograman berbasis aturan statis, terutama dalam menangani variasi kombinasi kebutuhan pengguna yang beragam.

6.2 Saran Pengembangan

1. Mengganti dataset manual dengan dataset SSD nyata yang diambil dari sumber harga dan spesifikasi resmi secara berkala, agar rekomendasi yang diberikan selalu relevan dengan kondisi pasar terkini.
2. Menambahkan arsitektur multilayer seperti Multilayer Perceptron dengan backpropagation untuk mengantisipasi kemungkinan aturan kompatibilitas yang menjadi tidak linear di masa depan, mengingat keterbatasan Perceptron satu lapis pada permasalahan non linear (Minsky & Papert, 1969).
3. Mengintegrasikan API harga SSD secara real time agar pertimbangan budget pada model LVQ selalu mencerminkan harga pasar yang aktual, mengingat harga SSD cenderung fluktuatif mengikuti pasokan NAND flash global (TrendForce, 2025).
4. Melakukan pengujian dengan jumlah data yang lebih besar dan beragam untuk mengukur akurasi model secara lebih representatif menggunakan teknik validasi seperti k-fold cross validation.

LAMPIRAN

A. Daftar Library yang Digunakan

Library	Fungsi
streamlit	Framework antarmuka aplikasi web interaktif berbasis Python.
numpy	Komputasi numerik dan operasi matriks untuk implementasi Perceptron dan LVQ dari prinsip dasar.
pandas	Manajemen struktur data dataset SSD dan riwayat rekomendasi dalam bentuk DataFrame.
matplotlib	Visualisasi pendukung pada proses eksplorasi data.
plotly	Visualisasi interaktif untuk grafik distribusi, harga, kapasitas, dan grafik training.
openpyxl	Mesin penulisan file Excel pada fitur ekspor riwayat rekomendasi.

B. Contoh Struktur Dataset SSD (5 dari 20 Data)

Nama SSD	Jenis	Kapasitas (GB)	Harga (Rp)	Read (MB/s)	Write (MB/s)	Kategori
Samsung 870 EVO 500GB	SATA	500	1015000	560	530	Mid Range
Kingston NV2 500GB	NVMe	500	699000	3500	2100	Mid Range
WD Blue SN580 1TB	NVMe	1000	1199000	4150	4150	High Performance
Crucial MX500 250GB	SATA	250	569000	560	510	Entry Level
Samsung 990 PRO 2TB	NVMe	2000	3199000	7450	6900	Professional

Catatan: harga bersifat estimasi untuk keperluan simulasi pelatihan model dan dapat berbeda dengan harga pasar aktual. Dataset lengkap berisi 20 baris data tersedia pada source code aplikasi (app.py).

C. Spesifikasi Teknis Aplikasi

- Bahasa pemrograman: Python 3.
- Framework antarmuka: Streamlit.

- Model JST: PerceptronFromScratch dan LVQFromScratch, diimplementasikan murni menggunakan NumPy tanpa pustaka machine learning eksternal.
- Penyimpanan riwayat: `st.session_state`, bersifat sementara selama aplikasi berjalan pada satu sesi browser.
- Cara menjalankan aplikasi: `streamlit run app.py` pada terminal setelah seluruh dependensi pada requirements terinstal.

DAFTAR PUSTAKA

- Atlantic.net. (2026). HDD vs SATA SSD vs NVMe SSD: Concepts and Performance. Diakses dari <https://www.atlantic.net/vps-hosting/hdd-vs-sata-ssd-vs-nvme-ssd-concepts/>
- Budianita, E., Santoso, E., & Rahayudi, B. (2013). Penerapan Learning Vector Quantization (LVQ) untuk Klasifikasi Status Gizi Anak. IJCCS (Indonesian Journal of Computing and Cybernetics Systems).
- Coherent Market Insights. (2026). Solid State Drive (SSD) Market Size and Analysis, 2026-2033. Diakses dari <https://www.coherentmarketinsights.com/market-insight/solid-state-drive-market-5778>
- Fausset, L. V. (1994). Fundamentals of Neural Networks: Architectures, Algorithms, and Applications. New Jersey: Prentice Hall.
- Grania. (2017). Penerapan Algoritma Perceptron pada Jaringan Syaraf Tiruan dalam Pembagian Jurusan. Jurnal Teknologi Informasi, Universitas Bunda Mulia.
- Hariri, F. R., Utami, E., & Amborowati, A. (2015). Learning Vector Quantization untuk Klasifikasi Abstrak Tesis. Citec Journal, 2(2), 128-143.
- Kapita, N. (2020). Penilaian Pengetahuan Siswa Dengan Jaringan Syaraf Tiruan Algoritma Perceptron. Techno: Jurnal Penelitian.
- Kohonen, T. (1986). Learning Vector Quantization for Pattern Recognition. Technical Report TKK-F-A601, Helsinki University of Technology.
- Kohonen, T. (1990). The Self-Organizing Map. Proceedings of the IEEE, 78(9), 1464-1480.
- Meliawati, R. (2016). Penerapan Metode Learning Vector Quantization (LVQ) pada Prediksi Jurusan di SMA PGRI 1 Banjarbaru. KLIK - Kumpulan Jurnal Ilmu Komputer, 4(1).
- Minsky, M., & Papert, S. (1969). Perceptrons: An Introduction to Computational Geometry. Cambridge, MA: MIT Press.
- Precedence Research. (2026). Solid State Drive (SSD) Market Size to Hit USD 304.73 Bn by 2035. Diakses dari <https://www.precedenceresearch.com/solid-state-drive-market>
- Pratama, A. B., Budianita, E., Yanti, N., & Candra, R. M. (2018). Implementasi Metode Learning Vector Quantization (LVQ) Untuk Sentimen Analisis Terhadap Aplikasi

- Go-Jek Pada Playstore. Jurnal Nasional Komputasi dan Teknologi Informasi, 5(3).
- Rosenblatt, F. (1958). The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain. *Psychological Review*, 65(6), 386-408.
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
- ServerMania. (2026). NVMe vs SATA Performance: Benchmarks, Latency, and Cost. Diakses dari <https://www.servermania.com/kb/articles/nvme-vs-sata-database-cache-performance>
- Siang, J. J. (2009). *Jaringan Syaraf Tiruan dan Pemrogramannya Menggunakan Matlab*. Yogyakarta: Andi Offset.
- TechTarget. (2024). NVMe Speeds vs. SATA and SAS: Which is Fastest? Diakses dari <https://www.techtarget.com/searchstorage/feature/NVMe-SSD-speeds-explained>
- 1gbits. (2026). NVMe vs SSD: Which Storage Option is Better for Speed, Performance, and Cost. Diakses dari <https://1gbits.com/blog/nvme-vs-ssd/>
- Yanto, M., Sovia, R., & Mandala, E. P. W. (2018). Jaringan Syaraf Tiruan Perceptron untuk Penentuan Pola Sistem Irigasi Lahan Pertanian di Kabupaten Pesisir Selatan Sumatra Barat. *Sebatik*, 22(2), 111-115.